

Università degli Studi di Padova
Dipartimento di Scienze Statistiche

Modelli statistici per dati economici

Studenti:
Brogniera Matteo & Saccon Pietro

Anno Accademico 2025-2026

Indice

1	Introduzione	3
2	Descrizione dei Dati	3
2.1	Fonti e Frequenza dei Dati	3
2.2	Serie Utilizzate	5
3	Analisi preliminare delle serie storiche	7
3.1	Visualizzazioni iniziali (livelli, ACF, PACF)	7
3.2	Trasformazione logaritmica e differenziazione	8
3.3	Cross-correlazioni (CCF)	9
4	Modello Transfer Function	13
4.1	Trasformazione e pre-whitening delle serie	13
4.2	Analisi della Correlazione Residuale	16
5	Modelli VAR	18
5.1	Trasformazione dei dati e selezione dell'ordine (p)	18
5.1.1	Modello VAR(1)	19
5.1.2	Modello VAR(3)	23
5.1.3	Modello VAR(12)	26
5.1.4	Scelta del modello finale	29
5.2	Test di diagnostica	29
5.2.1	Test Ljung-Box per l'autocorrelazione seriale univariata	29
5.2.2	Analisi della stabilità del modello	30
5.2.3	Test di normalità dei residui (Jarque-Bera)	30
5.2.4	Test di Portmanteau (Multivariato)	31
5.2.5	Test di Breusch-Godfrey (LM Test)	32
5.2.6	Test ARCH Multivariato	32
5.2.7	Test di causalità di Granger e causalità istantanea	32
5.2.8	Test di causalità di Granger bivariato	34
5.2.9	Analisi delle Funzioni di Risposta agli Impulsi (IRF)	36
5.2.10	Decomposizione della varianza dell'errore di previsione (FEVD)	37
5.3	Valutazione della performance predittiva	38
6	Analisi di Cointegrazione e Modello VECM	41
6.1	Test Augmented Dickey-Fuller (ADF)	41
6.2	Test di Johansen	46
6.3	Stima del modello VECM	48
6.4	Rappresentazione VAR del VECM	49
7	Conclusione	51

1 Introduzione

Il presente studio si pone l'obiettivo di analizzare le interdipendenze dinamiche tra il prezzo del petrolio, i prezzi alla produzione (PPI) e l'indice dei prezzi al consumo (CPI). Attraverso l'impiego di modelli econometrici per serie storiche, quali il Vector Autoregression (VAR) e il Vector Error Correction Model (VECM), l'analisi indaga sia la capacità predittiva reciproca delle variabili che l'esistenza di legami strutturali di lungo periodo. Particolare attenzione è rivolta alla diagnostica del modello e alla sua robustezza, testando la stabilità del sistema e la qualità dei residui, per poi passare a una valutazione della performance previsiva.

2 Descrizione dei Dati

In questo capitolo vengono presentate le serie storiche utilizzate nell'analisi. I dati sono stati scaricati dal database *Federal Reserve Economic Data* (FRED), una delle principali fonti internazionali per indicatori macroeconomici, finanziari e reali. L'obiettivo è costruire un dataset mensile, a partire dal 1970, contenente variabili rilevanti per lo studio dell'attività economica e delle dinamiche produttive negli Stati Uniti.

2.1 Fonti e Frequenza dei Dati

Le serie sono state scaricate tramite l'API ufficiale FRED utilizzando il pacchetto `fredr` in linguaggio R. Tutte le variabili selezionate sono già disponibili in frequenza mensile, pertanto non è stato necessario effettuare conversioni o aggregazioni. Il periodo considerato va da gennaio 1970 fino ad agosto 2025, compatibilmente con la disponibilità delle serie.

```
# scarica serie gemini:
# librerie:
library(fredr)
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.1.4      v readr      2.1.5
v forcats    1.0.1      v stringr    1.5.1
v ggplot2    3.5.2      v tibble     3.2.1
v lubridate  1.9.4      v tidyr      1.3.1
v purrr      1.0.4
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(lubridate)
library(writexl)
```

```
# Scarica e exel serie ----
# Set your FRED API key
fredr_set_key("2869b6dcb766b4ad6abab5fc37761494")
```

```
scarica_serie <- function(codice, nome_locale) {
  fredr(
    series_id = codice,
    observation_start = as.Date("1970-01-01"),
    frequency = "m",
    aggregation_method = "avg"
  ) %>%
  dplyr::select(date, value) %>%
  dplyr::rename(!!nome_locale := value)
}

# ----- LISTA SERIE
serie_mensili <- list(
  CPIAUCSL = "prezzi_consumo_cpi",
  WTISPLC  = "prezzo_petrolio",
  PPIACO   = "prezzi_produzione_ppi"
)

# ----- DOWNLOAD AND MERGE LOOP
mensili_df_final <- NULL # Inizializziamo il dataframe vuoto

for (codice in names(serie_mensili)) {

  nome_locale <- serie_mensili[[codice]]

  # Scarico la serie
  message(paste("Scaricamento di:", nome_locale, "..."))
  serie <- scarica_serie(codice, nome_locale)

  # Logica di unione
  if (is.null(mensili_df_final)) {
    mensili_df_final <- serie
  } else {
    mensili_df_final <- full_join(mensili_df_final, serie, by = "date")
  }
}
}
```

```
Scaricamento di: prezzi_consumo_cpi ...
Scaricamento di: prezzo_petrolio ...
Scaricamento di: prezzi_produzione_ppi ...
```

```
# Ordino per data per pulizia
mensili_df_final <- mensili_df_final %>% arrange(date)

# ----- EXPORT TO EXCEL
write_xlsx(
  list(
    "Dati_Economici" = mensili_df_final
  ),
  path = "serie_economici_fred.xlsx"
```

```
)

message("File Excel salvato: serie_economici_fred.xlsx")
```

File Excel salvato: serie_economici_fred.xlsx

```
# Intro ACF e CCF ----
library(readxl)
# 1. Leggi il file Excel
serie_mens <- read_excel("serie_economici_fred.xlsx")

# 2. Converti la colonna 'date' in oggetto Date (se non lo è già)
serie_mens$date <- as.Date(serie_mens$date)

# 3. Filtra il periodo desiderato
serie_mens_filtrata <- serie_mens %>%
  filter(date >= as.Date("1970-01-01") & date <= as.Date("2025-08-01"))

# 4. Crea oggetto ts (escludendo la colonna data)
data_mens <- ts(serie_mens_filtrata[, -1], start = c(1970, 1), frequency = 12)
```

2.2 Serie Utilizzate

Le variabili selezionate rappresentano indicatori chiave dell'attività economica reale e delle condizioni finanziarie. Le serie e i codici FRED utilizzati nel codice R sono i seguenti:

- Indice dei prezzi al consumo (CPI) (CPIAUCSL): misura il livello medio dei prezzi pagati dai consumatori urbani per un paniere rappresentativo di beni e servizi. È l'indicatore di riferimento per monitorare l'inflazione al consumo e valutare il potere d'acquisto delle famiglie. (<https://fred.stlouisfed.org/series/CPIAUCSL>)
- Prezzo spot del petrolio WTI (WTISPLC): rappresenta il prezzo di mercato del petrolio West Texas Intermediate, una delle principali benchmark crude oils a livello globale. È una variabile cruciale per comprendere l'evoluzione dei costi energetici e il loro impatto sull'economia reale. (<https://fred.stlouisfed.org/series/WTISPLC>)
- Indice dei prezzi alla produzione (PPI) (PPIACO): misura la variazione media dei prezzi ricevuti dai produttori per beni e servizi venduti sul mercato interno. È un indicatore anticipatore delle pressioni inflazionistiche lungo la catena produttiva. (<https://fred.stlouisfed.org/series/PPIACO>)

Il seguente codice mostra la struttura finale delle serie:

```
start(data_mens)
```

```
[1] 1970    1
```

```
end(data_mens)
```

```
[1] 2025    8
```

```
head(data_mens)
```

	prezzi_consumo_cpi	prezzo_petrolio	prezzi_produzione_ppi
[1,]	37.9	3.35	36.5
[2,]	38.1	3.35	36.7
[3,]	38.3	3.35	36.7
[4,]	38.5	3.35	36.8
[5,]	38.6	3.35	36.8
[6,]	38.8	3.35	36.9

```
tail(data_mens)
```


	prezzi_consumo_cpi	prezzo_petrolio	prezzi_produzione_ppi
[663,]	319.615	68.24	258.525
[664,]	320.321	63.54	258.392
[665,]	320.580	62.17	258.678
[666,]	321.500	68.17	260.491
[667,]	322.132	68.39	262.358
[668,]	323.364	64.86	262.119

3 Analisi preliminare delle serie storiche

In questa sezione vengono presentate le analisi esplorative condotte sulle serie storiche selezionate: *prezzi consumo cpi*, *prezzo petrolio* e *prezzi produzione ppi*. L'obiettivo è valutare la natura delle serie, la presenza di trend, stagionalità, autocorrelazione e la necessità di eventuali trasformazioni preliminari.

3.1 Visualizzazioni iniziali (livelli, ACF, PACF)

```
par(mfrow=c(3,3))
for(i in 1:3){
  ts.plot(data_mens[, i], ylab = colnames(data_mens)[i])
  acf(data_mens[, i], main="", lag=40)
  pacf(data_mens[, i], main="", lag=40)
}
```



```
par(mfrow = c(1,1))
```


Si osserva che:

- Le serie mostrano un trend e possibili effetti di crescita a lungo periodo (tipico per indici/serie di prezzi).
- Le ACF mostrano autocorrelazioni elevate e lente decrescenze, segnale di non stazionarietà.

3.2 Trasformazione logaritmica e differenziazione

Per rendere le serie confrontabili e stabilizzare la varianza abbiamo applicato la trasformazione logaritmica (data la natura delle serie che trattano prezzi o indici di prezzi) e la prima differenziazione:

```
serie_diff <- diff(log(data_mens))
par(mfrow=c(3,3))
for(i in 1:3){
  ts.plot(serie_diff[, i], ylab = colnames(serie_diff)[i])
  acf(serie_diff[, i], main="", lag=40)
  pacf(serie_diff[, i], main="", lag=40)
}
```




```
par(mfrow = c(1,1))
```

L'applicazione delle log-differenze ha rimosso efficacemente il trend nel prezzo del petrolio e nel PPI, stabilizzandone la media. Tuttavia, la lenta decrescita dell'ACF relativa ai prezzi al consumo (CPI) suggerisce che la serie conservi un'elevata persistenza o un trend residuo, indicando una stazionarietà incompleta nonostante la trasformazione.


3.3 Cross-correlazioni (CCF)

Le funzioni di correlazione incrociata (CCF) sono state calcolate per valutare le relazioni dinamiche tra le variabili.


```
### cross-correlazioni ----
prezzi_consumo_cpi <- data_mens[,1]
prezzo_petrolio <- data_mens[,2]
prezzi_produzione_ppi <- data_mens[,3]

par(mfcol=c(2,1))
ccf(prezzi_consumo_cpi, prezzo_petrolio, 30, col="red",
    main="CCF: prezzi_consumo_cpi e prezzo_petrolio")
ccf(diff(log(prezzi_consumo_cpi)), diff(log(prezzo_petrolio)), 30, col="red",
    main="CCF serie log-differenziate: prezzi_consumo_cpi e prezzo_petrolio")
```

CCF: prezzi_consumo_cpi e prezzo_petrolio



CCF serie log-differenziate: prezzi_consumo_cpi e prezzo_petrolio




```
par(mfcol=c(1,1))
```


L'analisi della funzione di cross-correlazione tra l'indice dei prezzi al consumo (CPI) e il prezzo del petrolio evidenzia due aspetti fondamentali: il primo grafico mostra valori di CCF costantemente elevati e persistenti. Tale pattern è sintomatico della non stazionarietà delle serie originali (presenza di trend), suggerendo il rischio di correlazione spuria. Il grafico inferiore, calcolato sulle prime differenze per garantire la stazionarietà, rivela la reale struttura di interdipendenza: si osserva un picco positivo significativo al lag zero, indicando che variazioni nel prezzo del petrolio si riflettono immediatamente sul CPI. La presenza di picchi significativi nei lag positivi suggerisce che il prezzo del petrolio agisce come variabile anticipatrice, influenzando il CPI nei periodi successivi. L'assenza di correlazione significativa nei lag negativi esclude un feedback inverso. In conclusione, l'analisi conferma una relazione diretta e unidirezionale: shock positivi nel mercato energetico tendono a trasmettersi ai prezzi al consumo sia istantaneamente che con una moderata persistenza temporale fino a quasi 3 mesi.

```
par(mfcol=c(2,1))
ccf(prezzi_consumo_cpi, prezzi_produzione_ppi, 30, col="red",
    main="CCF: prezzi_consumo_cpi e prezzi_produzione_ppi")
ccf(diff(log(prezzi_consumo_cpi)), diff(log(prezzi_produzione_ppi)), 30, col="red",
    main="CCF serie log-differenziate: prezzi_consumo_cpi e prezzi_produzione_ppi")
```

CCF: prezzi_consumo_cpi e prezzi_produzione_ppi





CCF serie log-differenziate: prezzi_consumo_cpi e prezzi_produzione_p



```
par(mfcol=c(1,1))
```

L'analisi della correlazione incrociata tra i prezzi al consumo (CPI) e i prezzi alla produzione evidenzia una dinamica di trasmissione dei costi: il grafico superiore conferma la presenza di trend comuni non stazionari, con una CCF che decade molto lentamente, rendendo necessaria l'analisi sulle differenze prime per identificare i legami. Il grafico inferiore mostra una struttura di lag più articolata rispetto al caso precedente: si osserva il picco più significativo in corrispondenza del lag zero, indicando una forte sincronia tra le variazioni dei costi di produzione e i prezzi al consumo finali. La persistenza di barre significative nei lag positivi indica che le variazioni dei prezzi alla produzione continuano a influenzare il CPI anche nei mesi successivi. Tra le due variabili si nota una relazione bilaterale.

```
par(mfcol=c(2,1))
ccf(prezzo_petrolio, prezzi_produzione_ppi, 30, col="red",
    main="CCF: prezzo_petrolio e prezzi_produzione_ppi")
ccf(diff(log(prezzo_petrolio)), diff(log(prezzi_produzione_ppi)), 30, col="red",
    main="CCF serie log-differenziate: prezzo_petrolio e prezzi_produzione_ppi")
```

CCF: prezzo_petrolio e prezzi_produzione_ppi**CCF serie log-differenziate: prezzo_petrolio e prezzi_produzione_ppi**

```
par(mfcol=c(1,1))
```

Il grafico mostra la funzione di cross-correlazione (CCF) tra il prezzo del petrolio e l'indice dei prezzi alla produzione. Nel primo riquadro, le serie mostrano una correlazione elevata e persistente per tutti i lag, riconducibile alla non-stazionarietà delle serie. Nel secondo riquadro, l'analisi sulle serie log-differenziate rivela la vera dinamica. La correlazione è massima e significativa al lag 0, indicando che la relazione tra le variazioni del prezzo del petrolio e del PPI è principalmente simultanea. È tuttavia di particolare interesse la presenza di valori significativi nei lag negativi. Questi suggeriscono che l'indice dei prezzi del petrolio funga da indicatore anticipatore per i prezzi alla produzione. In altre parole, le variazioni nei prezzi del petrolio tendono a precedere e riflettersi sui movimenti della produzione nei mesi successivi.

In conclusione notiamo che tutte e tre le serie sono cross-correlate simultaneamente e il prezzo del petrolio è una variabile guida per il prezzo al consumo e per il prezzo alla produzione.

4 Modello Transfer Function

In questa sezione è stato esplorato l'utilizzo di un modello *Transfer Function* (TF). Il modello *Transfer Function* (TF) è uno strumento utilizzato per analizzare la relazione tra **Prezzo del petrolio** e **Prezzo al consumo**. A differenza di una semplice regressione statica, il modello TF permette di catturare effetti ritardati, ovvero situazioni in cui l'input influenza l'output dopo un certo numero di periodi. L'obiettivo era verificare se esistesse un effetto ritardato, tale da giustificare l'applicazione di un modello TF.

4.1 Trasformazione e pre-whitening delle serie

```
library(MTS)      # tfm1
library(arfima)    # SeriesJ
```

Caricamento del pacchetto richiesto: ltsa

Note that the arfima package has new defaults starting with 1.4-0: type `arfimachanges()` for a list, as well as some other notes. NOTE: some of these are quite important!

Caricamento pacchetto: 'arfima'

Il seguente oggetto è mascherato da 'package:stats':

BIC

```
library(forecast) # Arima
```

Registered S3 method overwritten by 'quantmod':

```
method      from
as.zoo.data.frame zoo
```

Caricamento pacchetto: 'forecast'

Il seguente oggetto è mascherato da 'package:arfima':




arfima

```
y <- data_mens[,1] # variabile prezzi consumo
x <- data_mens[,2] # variabile prezzo petrolio
y <- diff(log(y))
x <- diff(log(x))
```

Le serie sono state trasformate per garantire la stazionarietà:



- La variabile input è stata log-differenziata: `diff(log(Prezzo del petrolio))`.
- La variabile output è stata log-differenziata: `diff(log(Prezzo consumi CPI))`.

```
par(mfcol = c(3,1))
acf(x, main = "ACF prezzo petrolio (log-diff)")
acf(y, main = "ACF prezzi consumi (log-diff)")
ccf(y, x, main = "CCF (y, x)")
```



```
par(mfcol = c(1,1))

par(mfcol = c(2,1))
acf(x)
pacf(x)
```



```
# modello per sbiancare corretto AR(1) o AR(2)
mx.1 <- Arima(x, order = c(1,0,0), include.mean = F)

mx.2 <- Arima(x, order = c(2,0,0), include.mean = F)

AIC(mx.1, mx.2)
```


	df	AIC
mx.1	2	-1345.929
mx.2	3	-1349.028

```
cbind(mx.1$bic, mx.2$bic)
```


	[,1]	[,2]
[1,]	-1336.923	-1335.52

```
# leggermente meglio il secondo modello per AIC, e meglio il primo modello per bic
# preferisco il primo perché più parsimonioso.
acf(mx.1$residuals, main="ACF modello AR(1)")
pacf(mx.1$residuals,, main="PACF modello AR(1)")
```

ACF modello AR(1)



PACF modello AR(1)



```
# i residui sono buoni
# dunque il modello scelto per sbiancare la serie y è il primo (AR(1)).

alfa <- mx.1$residuals


my.1 <- arima(y, order = c(1,0,0), include.mean = F,
              fixed = c(mx.1$coef[1]))

beta <- my.1$residuals
```

Successivamente, è stato stimato un modello AR(1) per l'input, scelto per la sua parsimonia e buone proprietà dei residui. I residui di questo modello (**alfa**) sono stati utilizzati come input sbiancato. Analogamente, è stato stimato un modello AR(1) per l'output, vincolando il coefficiente autoregressivo al valore stimato sull'input, ottenendo i residui **beta**. Questo permette di eliminare dalle serie le autocorrelazioni presenti e fare emergere la sola cross-correlazione tra le due.

4.2 Analisi della Correlazione Residuale


```
par(mfrow=c(1,1))  
ccf(alfa, beta, lag.max = 10, main = "CCF(alfa, beta)")
```



L'analisi della funzione di cross-correlazione (CCF) tra il prezzo del petrolio e l'indice dei prezzi al consumo, condotta dopo la fase di sbiancamento (pre-whitening) delle serie, evidenzia l'inadeguatezza di un modello di Transfer Function (TF) per descrivere questa relazione. Il grafico mostra infatti che il picco di correlazione più significativo si trova principalmente al lag 0, indicando un legame simultaneo anziché ritardato. Poiché un modello TF presuppone che la variabile di input influenzi l'output con un ritardo temporale misurabile, l'assenza di questa distanza rende il modello concettualmente inappropriato. Inoltre, la presenza di correlazione nei lag negativi suggerisce che l'indice dei prezzi del petrolio possa agire da indicatore anticipatore per i prezzi della produzione. In sintesi, la dinamica istantanea rilevata suggerisce di abbandonare il TF a favore di un modello VAR.

5 Modelli VAR

In questo capitolo viene implementato un modello di Vector Autoregression (VAR) per analizzare le interdipendenze dinamiche tra i prezzi al consumo (CPI), il prezzo del petrolio e i prezzi alla produzione (PPI). L'obiettivo è catturare come gli shock energetici e i costi di produzione si trasmettano lungo la catena del valore.

5.1 Trasformazione dei dati e selezione dell'ordine (p)

Per garantire la stazionarietà del sistema, necessaria per una stima corretta del VAR, le serie storiche originali sono state trasformate in differenze logaritmiche. Questa operazione permette di interpretare i dati in termini di tassi di variazione mensile, eliminando i trend deterministici comuni alle tre variabili. Un passaggio critico nella costruzione del modello è la scelta del numero di ritardi (p). Un numero troppo esiguo di lag potrebbe non catturare l'intera dinamica del sistema, mentre un numero eccessivo rischierebbe di ridurre drasticamente i gradi di libertà (overfitting).

```
library(vars)
```

```
Caricamento del pacchetto richiesto: MASS
```

```
Caricamento pacchetto: 'MASS'
```

```
Il seguente oggetto è mascherato da 'package:dplyr':
```

```
select
```

```
Caricamento del pacchetto richiesto: strucchange
```

```
Caricamento del pacchetto richiesto: zoo
```

```
Caricamento pacchetto: 'zoo'
```

```
I seguenti oggetti sono mascherati da 'package:base':
```

```
as.Date, as.Date.numeric
```

```
Caricamento del pacchetto richiesto: sandwich
```

```
Caricamento pacchetto: 'strucchange'
```

```
Il seguente oggetto è mascherato da 'package:stringr':
```

```
boundary
```

Caricamento del pacchetto richiesto: urca

Caricamento del pacchetto richiesto: lmtest

Caricamento pacchetto: 'vars'

Il seguente oggetto è mascherato da 'package:MTS':

VAR

```
library(urca)
library(lmtest)

data_trans <- data_mens
# Trasformazione Log-Difference per tutte le serie
data_trans[,1] <- c(NA, diff(log(data_mens[,1])))
data_trans[,2] <- c(NA, diff(log(data_mens[,2])))
data_trans[,3] <- c(NA, diff(log(data_mens[,3])))
# Rimuovi la prima riga che conterrà NA a causa della differenziazione
data_trans <- na.omit(data_trans)
ICsel <- VARselect(data_trans, lag.max = 20, type = "const")
ICsel$selection
```

AIC(n)	HQ(n)	SC(n)	FPE(n)
12	3	1	12

Per determinare il valore ottimale di p , sono stati calcolati i criteri di informazione su un massimo di 20 ritardi:

- Schwarz Criterion (SC): Suggerisce il modello più parsimonioso con 1 solo lag, minimizzando il rischio di sovra-parametrizzazione.
- Hannan-Quinn (HQ): Indica un compromesso con 3 lag, valore spesso preferito in letteratura per dati mensili poiché bilancia precisione e semplicità.
- Akaike Information Criterion (AIC): Propone un modello più complesso con 12 lag, probabilmente per catturare la stagionalità annuale o le dinamiche più persistenti del CPI.


Data la natura mensile dei dati e la necessità di modellare la trasmissione degli shock che tipicamente richiede diversi mesi per manifestarsi pienamente, si procede con la stima dei modelli basati sulla scelta del numero di questi ritardi (p).

5.1.1 Modello VAR(1)


```
# VAR con p=1 ----
modL1 <- vars::VAR(data_trans, p = 1, type = "const")
# Valutazione residui
res_modL1 <- resid(modL1)
head(res_modL1)
```

	prezzi_consumo_cpi	prezzo_petrolio	prezzi_produzione_ppi
1	0.0008946352	-0.003051766	-0.0039409125
2	0.0008019262	-0.002438829	-0.0001043591
3	-0.0017558525	-0.002756419	-0.0033691350
4	0.0023046379	-0.003236197	0.0006466544
5	-0.0017524087	-0.014779923	0.0020493719
6	-0.0001234495	-0.001036398	-0.0082787390

```
plot.ts(res_modL1)
```




```
par(mfrow = c(3, 2))
for(i in 1:NCOL(res_modL1)){
  acf(res_modL1[,i], main = colnames(res_modL1)[i])
  pacf(res_modL1[,i], main = colnames(res_modL1)[i])
}
```



```
par(mfrow = c(1, 1))

par(mfrow = c(3, 1))
ccf(res_modL1[, 1], res_modL1[, 2], main = "consumi & petrolio")
ccf(res_modL1[, 1], res_modL1[, 3], main = "consumi & produzione")
ccf(res_modL1[, 2], res_modL1[, 3], main = "produzione & petrolio")
```



```
par(mfrow = c(1, 1))
cor(res_modL1)
```

	prezzi_consumo_cpi	prezzo_petrolio	prezzi_produzione_ppi
prezzi_consumo_cpi	1.0000000	0.4150522	0.6065885
prezzo_petrolio	0.4150522	1.0000000	0.5537752
prezzi_produzione_ppi	0.6065885	0.5537752	1.0000000

Il modello VAR(1) rappresenta la struttura più semplice, basata sulla memoria del solo mese precedente.


- Il prezzo del petrolio al tempo $t - 1$ influenza positivamente sia il CPI ($p < 0.001$) che il PPI ($p < 0.001$). Tuttavia, l' R^2 per il prezzo del petrolio è molto basso (0.056), confermando che questa variabile è prevalentemente esogena rispetto al sistema.
- I grafici ACF e PACF dei residui mostrano tipicamente picchi oltre le soglie di confidenza, indicando che un modello con $p = 1$ non elimina l'autocorrelazione. Le matrici di correlazione dei residui mostrano valori elevati (0.60 tra CPI e PPI), suggerendo la presenza di forti shock simultanei non catturati dal modello.

5.1.2 Modello VAR(3)


```
modL2 <- vars::VAR(y = data_trans, p = 3, type = "const")
## Res modL2 ----
res_modL2 <- resid(modL2)
head(res_modL2)
```

	prezzi_consumo_cpi	prezzo_petrolio	prezzi_produzione_ppi
1	-0.0019334521	-0.002578915	-0.0030434949
2	0.0017337128	-0.008320980	0.0002558621
3	-0.0017826450	-0.015833516	0.0025383322
4	-0.0002569978	-0.003026833	-0.0079593959
5	0.0017594383	-0.008533063	0.0032635690
6	0.0013594144	0.004911230	-0.0023191520

```
plot.ts(res_modL2)
```




```
par(mfrow = c(3, 2))
for(i in 1:NCOL(res_modL2)){
  acf(res_modL2[,i], main = colnames(res_modL2)[i])
  pacf(res_modL2[,i], main = colnames(res_modL2)[i])
}
```



```
par(mfrow = c(1, 1))

par(mfrow = c(3, 1))
ccf(res_modL2[, 1], res_modL2[, 2], main = "consumi & petrolio")
ccf(res_modL2[, 1], res_modL2[, 3], main = "consumi & produzione")
ccf(res_modL2[, 2], res_modL2[, 3], main = "produzione & petrolio")
```

```
par(mfrow = c(1, 1))
cor(res_modL2)
```

	prezzi_consumo_cpi	prezzo_petrolio	prezzi_produzione_ppi
prezzi_consumo_cpi	1.0000000	0.4093562	0.6079514
prezzo_petrolio	0.4093562	1.0000000	0.5630674
prezzi_produzione_ppi	0.6079514	0.5630674	1.0000000

Il modello VAR(3), suggerito dal criterio HQ, estende l'analisi a un trimestre.


- Questo modello rivela che l'impatto del petrolio sul CPI non è solo immediato ($t - 1$), ma presenta un effetto di "ritorno" negativo e significativo al lag 2 e 3. Questo suggerisce una dinamica di aggiustamento dei prezzi più complessa.
- Le radici del polinomio caratteristico sono tutte in modulo minori di uno (valore massimo 0.81), garantendo che il sistema sia stazionario e che gli shock convergano nel tempo.

5.1.3 Modello VAR(12)


```
# VAR p=12 (come consigliato da AIC) ----
modL3 <- vars::VAR(y = data_trans, p = 12, type = "const")
```

Os

```
## Res modL3 ----
res_modL3 <- resid(modL3)
plot.ts(res_modL3)
```




```
par(mfrow = c(3, 2))
for(i in 1:NCOL(res_modL3)){
  acf(res_modL3[,i], main = colnames(res_modL3)[i])
  pacf(res_modL3[,i], main = colnames(res_modL3)[i])
}
```



```
par(mfrow = c(1, 1))

par(mfrow = c(3, 1))
ccf(res_modL3[, 1], res_modL3[, 2], main = "consumi & petrolio")
ccf(res_modL3[, 1], res_modL3[, 3], main = "consumi & produzione")
ccf(res_modL3[, 2], res_modL3[, 3], main = "produzione & petrolio")
```



```
par(mfrow = c(1, 1))
cor(res_modL3)
```

	prezzi_consumo_cpi	prezzo_petrolio	prezzi_produzione_ppi
prezzi_consumo_cpi	1.0000000	0.4238654	0.6231127
prezzo_petrolio	0.4238654	1.0000000	0.5609466
prezzi_produzione_ppi	0.6231127	0.5609466	1.0000000

Il modello VAR(12), suggerito dall'AIC, è il più complesso e mira a catturare l'intera dinamica annuale.

- In questo modello, molte variabili perdono significatività individuale a causa dell'elevato numero di parametri (overfitting), ma la capacità descrittiva complessiva aumenta (R^2 del CPI sale a 0.54). È interessante notare come il CPI al lag 12 sia fortemente significativo, confermando la presenza di una stagionalità o di una memoria di lungo periodo nei prezzi al consumo.
- Il VAR(12) è l'unico modello che riduce drasticamente l'autocorrelazione seriale. Tuttavia, i grafici evidenziano "cluster di volatilità": i residui non hanno un'ampiezza costante, indicando che sebbene la media sia spiegata, la varianza (l'incertezza) cambia nel tempo (effetti ARCH).

5.1.4 Scelta del modello finale

```
round(ICsel$criteria[,c(1,3,12)], 4)
```

	1	3	12
AIC(n)	-27.0489	-27.1294	-27.2736
HQ(n)	-27.0167	-27.0490	-26.9759
SC(n)	-26.9659	-26.9221	-26.5063
FPE(n)	0.0000	0.0000	0.0000

Per la selezione definitiva del numero di ritardi, si è proceduto a un confronto tra i diversi criteri di informazione. Sebbene i criteri di Schwarz (SC) e Hannan-Quinn (HQ) suggeriscano modelli più parsimoniosi rispettivamente con 1 e 3 lag, si è scelto di adottare la specifica con 12 ritardi indicata dall'Akaike Information Criterion (AIC), che presenta il valore più basso (-27.2735). Tale scelta è supportata dalla “regola del pollice” comunemente utilizzata nell'analisi di dati mensili: impostare $p = 12$ permette infatti di catturare l'intera dinamica annuale e di correggere eventuali componenti stagionali residue, garantendo una completa rimozione dell'autocorrelazione dai residui, come confermato dai test diagnostici.

5.2 Test di diagnostica

In questa sezione vengono eseguiti i test statistici per validare la robustezza del modello VAR(12) stimato. L'obiettivo è verificare che i residui non presentino strutture sistematiche residue.

5.2.1 Test Ljung-Box per l'autocorrelazione seriale univariata

```
pval <- matrix(NA, 2, NCOL(res_modL3))
colnames(pval) <- colnames(res_modL3)
rownames(pval) <- c("r", "r^2")
for(i in 1:NCOL(res_modL3)){
  pval[1,i] <- Box.test(res_modL3[,i], lag=36, type="Lj")$p.val
  pval[2,i] <- Box.test(res_modL3[,i]^2, lag=36, type="Lj")$p.val
}
round(pval, 5)
```

	prezzi_consumo_cpi	prezzo_petrolio	prezzi_produzione_ppi
r	0.9221	0.95406	0.45054
r^2	0.0000	0.00033	0.00000

Per convalidare statisticamente il modello VAR(12), è stato eseguito il test di Ljung-Box sui residui (r) e sui residui al quadrato (r^2). Questo doppio controllo permette di verificare sia la corretta specifica della media (assenza di memoria lineare) sia la costanza della varianza (omoschedasticità). Dall'analisi della matrice dei p-value si traggono le seguenti conclusioni:

- Assenza di Autocorrelazione (r): i p-value relativi ai residui lineari sono estremamente elevati per tutte le variabili (0.922 per il CPI, 0.954 per il petrolio e 0.450 per il PPI). Non potendo rifiutare l'ipotesi nulla di indipendenza, si conferma che il modello a 12 lag cattura integralmente la dinamica temporale delle serie, trasformando i residui in rumore bianco.
- Presenza di Effetti ARCH (r^2): al contrario, i p-value calcolati sui residui al quadrato sono prossimi allo zero per ogni equazione del sistema. Il netto rifiuto dell'ipotesi nulla indica una forte presenza di eteroschedasticità.

5.2.2 Analisi della stabilità del modello

```
roots(modL3)
```

```
[1] 0.9700415 0.8988499 0.8988499 0.8914859 0.8914859 0.8902662 0.8902662
[8] 0.8834691 0.8834691 0.8699463 0.8699463 0.8649251 0.8649251 0.8630973
[15] 0.8614026 0.8614026 0.8524830 0.8478797 0.8478797 0.8320032 0.8320032
[22] 0.8231609 0.8231609 0.8032169 0.8032169 0.7940081 0.7940081 0.7926147
[29] 0.7926147 0.7911937 0.7911937 0.7670203 0.7670203 0.6641380 0.6641380
[36] 0.5544619
```

Un requisito fondamentale per l'affidabilità di un modello VAR è la sua stabilità. Un sistema è considerato stabile se, a seguito di uno shock esogeno, le variabili tendono a tornare nel tempo verso il loro equilibrio di lungo periodo anziché divergere all'infinito. Tecnicamente, la stabilità viene verificata analizzando le radici del polinomio caratteristico associato alla matrice dei coefficienti del VAR. Per la condizione di stabilità, è necessario che il modulo di tutte le radici sia strettamente inferiore a uno. L'output del comando mostra che tutti i 36 valori calcolati sono inferiori a 1. In conclusione il modello soddisfa la condizione di stabilità. Questo risultato garantisce la validità statistica delle analisi successive, in particolare per il calcolo delle Funzioni di Risposta Impulso (IRF) e della Decomposizione della Varianza (FEVD), poiché assicura che gli effetti degli shock si esauriscano gradualmente nel tempo senza rendere il sistema esplosivo.

5.2.3 Test di normalità dei residui (Jarque-Bera)

```
normality.test(modL3)
```

```
$JB
```

```
JB-Test (multivariate)
```

```
data: Residuals of VAR object modL3
```

```
Chi-squared = 5515.1, df = 6, p-value < 2.2e-16
```

```
$Skewness
```

```
Skewness only (multivariate)
```

```
data: Residuals of VAR object modL3  
Chi-squared = 92.378, df = 3, p-value < 2.2e-16
```

\$Kurtosis

Kurtosis only (multivariate)

```
data: Residuals of VAR object modL3  
Chi-squared = 5422.7, df = 3, p-value < 2.2e-16
```

Il test di Jarque-Bera (JB) verifica se i residui del modello seguono una distribuzione normale, analizzando congiuntamente due parametri fondamentali: l'asimmetria (Skewness) e la curtosi (Kurtosis). Dall'output del test multivariato emergono i seguenti risultati:

- Test JB Complessivo: il p-value è estremamente basso, portando al netto rifiuto dell'ipotesi nulla di normalità.
- Asimmetria (Skewness): il p-value quasi nullo indica che i residui non sono distribuiti simmetricamente attorno alla media.
- Curtosi (Kurtosis): il valore del Chi-quadrato è molto elevato (5422.6). Ciò significa che la distribuzione dei residui ha "code pesanti", ovvero si verificano shock estremi con una frequenza molto superiore a quella prevista da una distribuzione normale.

5.2.4 Test di Portmanteau (Multivariato)

```
serial.test(modL3, lags.pt=36, type = "PT.asymptotic")
```

Portmanteau Test (asymptotic)

```
data: Residuals of VAR object modL3  
Chi-squared = 241.44, df = 216, p-value = 0.113
```

Il test di Portmanteau è una verifica collettiva che analizza se i residui del sistema VAR nel suo insieme siano correlati fino a un certo numero di ritardi (in questo caso, 36). Serve a confermare che non vi sia informazione lineare residua trascurata dal modello. Il p-value ottenuto è 0.1133. Poiché il p-value è superiore alla soglia critica di 0.05, non rifiutiamo l'ipotesi nulla (assenza di autocorrelazione residua nel sistema). Questo risultato è di fondamentale importanza: a differenza del test eseguito su un modello con meno lag, il VAR(12) supera il test di Portmanteau. Questo conferma definitivamente che la scelta di un ordine di ritardo elevato ($p = 12$) è stata corretta e necessaria per "ripulire" i residui e ottenere un modello statisticamente solido.

5.2.5 Test di Breusch-Godfrey (LM Test)

```
serial.test(modL3, lags.bg = 36, type = "BG")
```

Breusch-Godfrey LM test

```
data: Residuals of VAR object modL3  
Chi-squared = 331.42, df = 324, p-value = 0.3762
```

Proseguendo con la diagnostica sull'autocorrelazione è stato usato il test di Breusch-Godfrey (LM), generalmente considerato più robusto e affidabile in presenza di variabili endogene ritardate e quando non è garantita la perfetta normalità dei residui. Il test, calcolato su 36 ritardi, restituisce un p-value di 0.3765. Il valore è ampiamente superiore alla soglia critica dello 0.05, portando a non rifiutare l'ipotesi nulla di assenza di correlazione seriale. Questo risultato è particolarmente confortante: sebbene i test univariati avessero già dato esito positivo, la conferma multivariata tramite il test LM consolida l'idea che la struttura del VAR(12) sia ottimale.

5.2.6 Test ARCH Multivariato

```
arch.test(modL3, lags.multi = 36)
```

ARCH (multivariate)

```
data: Residuals of VAR object modL3  
Chi-squared = 1685.6, df = 1296, p-value = 1.185e-12
```

La diagnostica riguarda la verifica della varianza costante nel tempo attraverso il test ARCH multivariato. Questo test analizza se esistano effetti di eteroschedasticità condizionata che colpiscono il sistema nel suo complesso, ovvero se la turbolenza in una variabile tenda a trasmettersi o a persistere nel sistema. Il test restituisce un Chi-quadrato di 1685.6 con un p-value estremamente basso. L'ipotesi nulla di omoschedasticità viene respinta.

5.2.7 Test di causalità di Granger e causalità istantanea

```
causality(modL3, cause="prezzi_consumo_cpi")
```

\$Granger

```
Granger causality H0: prezzi_consumo_cpi do not Granger-cause  
prezzo_petrolio prezzi_produzione_ppi
```

```
data: VAR object modL3
```


F-Test = 2.0784, df1 = 24, df2 = 1854, p-value = 0.001632

\$Instant

H0: No instantaneous causality between: prezzi_consumo_cpi and
prezzo_petrolio prezzi_produzione_ppi

data: VAR object modL3

Chi-squared = 185.91, df = 2, p-value < 2.2e-16

```
causality(modL3, cause="prezzo_petrolio")
```

\$Granger

Granger causality H0: prezzo_petrolio do not Granger-cause
prezzi_consumo_cpi prezzi_produzione_ppi

data: VAR object modL3

F-Test = 3.9236, df1 = 24, df2 = 1854, p-value = 5.764e-10

\$Instant

H0: No instantaneous causality between: prezzo_petrolio and
prezzi_consumo_cpi prezzi_produzione_ppi

data: VAR object modL3

Chi-squared = 160.17, df = 2, p-value < 2.2e-16

```
causality(modL3, cause="prezzi_produzione_ppi")
```

\$Granger

Granger causality H0: prezzi_produzione_ppi do not Granger-cause
prezzi_consumo_cpi prezzo_petrolio

data: VAR object modL3

F-Test = 1.4751, df1 = 24, df2 = 1854, p-value = 0.0644

\$Instant

H0: No instantaneous causality between: prezzi_produzione_ppi and
prezzi_consumo_cpi prezzo_petrolio

data: VAR object modL3

Chi-squared = 217.07, df = 2, p-value < 2.2e-16

Il test di Granger implica una causalità, intesa come una capacità predittiva statistica. L'ipotesi nulla (H_0) afferma che la variabile “causa” non aiuta a prevedere le altre variabili del sistema.

- Prezzo del petrolio: il p-value è estremamente basso (5.754×10^{-10}), quindi rifiutiamo con forza H_0 . Il petrolio risulta la variabile più esogena e influente del sistema. I suoi ritardi hanno un forte potere predittivo su CPI e PPI, in linea con la teoria economica secondo cui gli shock energetici si propagano rapidamente lungo la filiera dei prezzi.
- Prezzi al consumo (CPI): il p-value è pari a 0.0016, quindi rifiutiamo H_0 . Il CPI mostra capacità predittiva significativa, sebbene inferiore a quella del petrolio. Ciò può riflettere meccanismi di retroazione in cui l'inflazione attesa influenza le decisioni di produzione.
- Prezzi alla produzione (PPI): il p-value è pari a 0.0644; accettiamo H_0 ai livelli di confidenza standard (1% e 5%). Una volta inclusi petrolio e CPI nel sistema con 12 ritardi, il PPI non aggiunge informazione predittiva significativa. Il suo contenuto informativo sembra già incorporato nei movimenti del prezzo del petrolio.

5.2.8 Test di causalità di Granger bivariato

```
grangertest(data_trans[,1], data_trans[,2], order=12)
```

Granger causality test

```
Model 1: data_trans[, 2] ~ Lags(data_trans[, 2], 1:12) + Lags(data_trans[, 1], 1:12)
Model 2: data_trans[, 2] ~ Lags(data_trans[, 2], 1:12)
  Res.Df  Df      F    Pr(>F)
1     630
2     642 -12 2.7044 0.001437 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
grangertest(data_trans[,1], data_trans[,3], order=12)
```

Granger causality test

```
Model 1: data_trans[, 3] ~ Lags(data_trans[, 3], 1:12) + Lags(data_trans[, 1], 1:12)
Model 2: data_trans[, 3] ~ Lags(data_trans[, 3], 1:12)
  Res.Df  Df      F    Pr(>F)
1     630
2     642 -12 3.3406 9.868e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
grangertest(data_trans[,3], data_trans[,1], order=12)
```

Granger causality test

```
Model 1: data_trans[, 1] ~ Lags(data_trans[, 1], 1:12) + Lags(data_trans[, 3], 1:12)
Model 2: data_trans[, 1] ~ Lags(data_trans[, 1], 1:12)
  Res.Df  Df      F    Pr(>F)
1     630
```

```
2    642 -12 2.5536 0.002644 **
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
grangertest(data_trans[,3], data_trans[,2], order=12)
```

Granger causality test

```
Model 1: data_trans[, 2] ~ Lags(data_trans[, 2], 1:12) + Lags(data_trans[, 3], 1:12)
```

```
Model 2: data_trans[, 2] ~ Lags(data_trans[, 2], 1:12)
```

```
Res.Df Df      F Pr(>F)
```

```
1    630
```

```
2    642 -12 2.6192 0.00203 **
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
grangertest(data_trans[,2], data_trans[,1], order=12)
```

Granger causality test

```
Model 1: data_trans[, 1] ~ Lags(data_trans[, 1], 1:12) + Lags(data_trans[, 2], 1:12)
```

```
Model 2: data_trans[, 1] ~ Lags(data_trans[, 1], 1:12)
```

```
Res.Df Df      F Pr(>F)
```

```
1    630
```

```
2    642 -12 6.6169 3.128e-11 ***
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
grangertest(data_trans[,2], data_trans[,3], order=12)
```

Granger causality test

```
Model 1: data_trans[, 3] ~ Lags(data_trans[, 3], 1:12) + Lags(data_trans[, 2], 1:12)
```

```
Model 2: data_trans[, 3] ~ Lags(data_trans[, 3], 1:12)
```

```
Res.Df Df      F Pr(>F)
```

```
1    630
```

```
2    642 -12 4.2255 1.967e-06 ***
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Abbiamo integrato i test di sistema con i test di Granger bivariati, analizzando ogni possibile coppia di variabili. Mentre il test di sistema ci diceva se una variabile influenzava le altre, questi test isolano le casualità specifiche. Dall'analisi emerge un sistema caratterizzato da una fortissima interdipendenza: il legame più potente è quello che va dal Petrolio al CPI. Questo è coerente con i risultati precedentemente ottenuti. A differenza del test di sistema precedente, il test bivariato rivela una causalità bidirezionale tra prezzi alla produzione e prezzi al consumo. I test bivariati mostrano che ogni variabile apporta un contributo informativo significativo per prevedere le altre. Questo risultato giustifica pienamente l'utilizzo di un modello VAR rispetto a modelli a singola equazione, poiché nessuna variabile può essere considerata puramente esogena nel lungo periodo.


5.2.9 Analisi delle Funzioni di Risposta agli Impulsi (IRF)

```


irf_chol <- irf(modL3, impulse = c("prezzi_consumo_cpi", "prezzo_petrolio",
                                   "prezzi_produzione_ppi"),
               response = c("prezzi_consumo_cpi", "prezzo_petrolio",
                             "prezzi_produzione_ppi"),
               n.ahead = 12, boot = TRUE, ortho = TRUE, runs = 1000)
par(mfrow = c(3,3))
plot(irf_chol, plot.type = "single")

```


onal Impulse Response from prezzi_conal Impulse Response from prezzi_conal Impulse Response from prezzi_c



gonal Impulse Response from prezzogonal Impulse Response from prezzogonal Impulse Response from prezz



ial Impulse Response from prezzi_prial Impulse Response from prezzi_prial Impulse Response from prezzi_pri



```

par(mfrow = c(1,1))

```


In questa sezione analizziamo graficamente come il sistema reagisce a uno shock esogeno (una variazione imprevista) in una delle tre variabili. Le Funzioni di Risposta Impulso (IRF) permettono di osservare la grandezza, la direzione e la durata degli effetti di tali shock sull'intero orizzonte temporale di 12 mesi. Le bande di confidenza (linee tratteggiate rosse) sono state calcolate tramite 1000 repliche Bootstrap, garantendo la validità statistica nonostante la non-normalità dei residui.

Osservando la dinamica innescata dal prezzo del petrolio, lo shock si manifesta con la massima intensità nel momento iniziale per poi riassorbirsi gradualmente entro l'anno, confermando una

persistenza moderata. È interessante notare come un aumento imprevisto del petrolio generi una pressione al rialzo immediata sia sui prezzi alla produzione che su quelli al consumo; in particolare, la risposta del CPI risulta decisamente persistente. Le IRF confermano che il prezzo del petrolio agisce come il principale motore del sistema, innescando reazioni a catena che influenzano l'intera struttura dei prezzi. La stabilità complessiva del modello è visibile nella tendenza di tutte le risposte a convergere verso lo zero entro i 12 mesi.

5.2.10 Decomposizione della varianza dell'errore di previsione (FEVD)

```
vd <- fevd(modL3, n.ahead = 36)
plot(vd)
```



L'analisi si conclude con la Decomposizione della Varianza (FEVD), che permette di quantificare l'importanza relativa di ogni variabile nello spiegare l'incertezza del sistema nel tempo.

Per quanto riguarda i prezzi al consumo (CPI), la variabilità è dominata quasi interamente dalla componente inerziale. Sebbene nel brevissimo periodo il CPI spieghi il 100% di se stesso, già dopo pochi mesi il prezzo del petrolio arriva a determinare circa l'8-9% della sua varianza, mentre il contributo dei prezzi alla produzione (PPI) rimane marginale, stabilizzandosi intorno al 3%. Il

prezzo del petrolio si conferma la variabile guida: oltre il 77% della sua variabilità di lungo periodo è spiegata da shock propri, consolidando il suo ruolo di motore esogeno del sistema. Al contrario, i prezzi alla produzione (PPI) risultano essere i più dipendenti dalle dinamiche esterne. A un orizzonte di tre anni, la varianza del PPI è spiegata per circa il 41% dal CPI e per il 17% dal petrolio, lasciando solo una quota paritaria alla propria componente autonoma.

5.3 Valutazione della performance predittiva

L'ultima fase dell'analisi consiste nel testare la capacità del modello VAR di generare previsioni accurate per il CPI, confrontandola con un modello benchmark univariato (ARIMA (1,0,3 con drift)). La valutazione è stata effettuata tramite una procedura di rolling window su un orizzonte di 2 anni.

```
Y <- data_trans
target <- "prezzi_consumo_cpi" # <-- cambiabile
H <- 24 # <-- orizzonte 2 anni
win <- 500 # <-- rolling window length
#errori VAR e errori Univariato
eV <- eU <- matrix(NA, nrow = (nrow(Y) - win - H + 1), ncol = H,
  dimnames = list(NULL, paste0("h", 1:H)))
r <- 1
for (t in win:(nrow(Y) - H)) {
  tr <- 1:t # expanding window
  te <- (t + 1):(t + H)
  # --- VAR multivariato ---
  s <- VARselect(Y[1:t,], lag.max = 12, type = "const")
  #scelgo col il AIC (var (12))
  p <- s$selection[1]
  fcV <- predict(vars::VAR(Y[tr, ], p = p, type = "const"), n.ahead = H)
  yhatV <- fcV$fcst[[target]][1:H, "fcst"]
  # --- ARIMA univariato ---
  fitU <- auto.arima(Y[tr, target], seasonal = FALSE, d = 0, D = 0)
  yhatU <- as.numeric(forecast(fitU, h = H)$mean)
  # --- Valori veri e errori per orizzonte ---
  ytrue <- Y[te, target]
  eV[r, ] <- ytrue - yhatV
  eU[r, ] <- ytrue - yhatU
  r <- r + 1
}

# --- Valutazione per ciascun orizzonte ---
RMSE_VAR <- sqrt(colMeans(eV^2, na.rm = TRUE))
RMSE_UNI <- sqrt(colMeans(eU^2, na.rm = TRUE))

DM <- sapply(1:H, function(h)
  forecast::dm.test(eV[, h], eU[, h], h = H, power = 2,
    varestimator = "bartlett")$p.value
)
results <- data.frame(h = 1:H, RMSE_VAR, RMSE_UNI, DM_pval = DM)
print(results)
```

h	RMSE_VAR	RMSE_UNI	DM_pval
---	----------	----------	---------

h1	1	0.002266044	0.002352966	0.34252819
h2	2	0.002703577	0.002653985	0.62713624
h3	3	0.002784380	0.002652577	0.16883480
h4	4	0.002803643	0.002669079	0.05937110
h5	5	0.002820122	0.002698734	0.07128285
h6	6	0.002884482	0.002771531	0.09553665
h7	7	0.002861555	0.002771574	0.23746941
h8	8	0.002880531	0.002825381	0.43423439
h9	9	0.002904589	0.002899513	0.93229143
h10	10	0.002832688	0.002850612	0.80290563
h11	11	0.002799628	0.002878918	0.35442897
h12	12	0.002825207	0.002929505	0.20636835
h13	13	0.002847156	0.002992505	0.08113498
h14	14	0.002872897	0.002980324	0.07533079
h15	15	0.002856281	0.002902156	0.40335819
h16	16	0.002878799	0.002957390	0.07000720
h17	17	0.002877667	0.002984178	0.02707253
h18	18	0.002881880	0.002977976	0.06564722
h19	19	0.002879951	0.002976515	0.06121967
h20	20	0.002851386	0.002939350	0.04163540
h21	21	0.002862562	0.002940054	0.05463224
h22	22	0.002855032	0.002938731	0.10316346
h23	23	0.002900892	0.002969448	0.14583882
h24	24	0.002891911	0.002963975	0.15289334

Dalle previsioni possiamo vedere che il modello VAR(12) generalmente predice meglio rispetto al modello ARIMA per lag superiori a 9.

```
c(RMSE_VAR = sqrt(mean(eV^2)), RMSE_ARIMA = sqrt(mean(eU^2)))
```

```
RMSE_VAR  RMSE_ARIMA
0.002828703 0.002857261
```

Analizzando l'errore quadratico medio, si osserva che il modello VAR presenta un RMSE complessivo di 0.00283, leggermente inferiore a quello del modello ARIMA (0.00286). Questo suggerisce che, in media, l'integrazione delle informazioni provenienti dal prezzo del petrolio e dal PPI migliori la precisione delle previsioni sull'inflazione al consumo rispetto a un modello che utilizza esclusivamente i dati passati del CPI stesso.

```
forecast::dm.test(eV, eU, h = H, power = 2)
```

Diebold-Mariano Test

```
data: eVeU
DM = -2.1482, Forecast horizon = 24, Loss function power = 2, p-value =
0.03177
alternative hypothesis: two.sided
```

È stato applicato il test di Diebold-Mariano per determinare se la capacità previsiva del modello VAR sia migliore rispetto al modello ARIMA. Il p-value finale è pari a 0.03177, essendo il valore inferiore allo 0.05, rifiutiamo l'ipotesi nulla di uguale accuratezza predittiva. Possiamo quindi affermare con confidenza statistica che il modello VAR(12) fornisce previsioni significativamente migliori rispetto al modello univariato.

6 Analisi di Cointegrazione e Modello VECM

Dall'analisi preliminare è emerso che le serie storiche in esame presentano una natura non stazionaria, suggerendo la presenza di radici unitarie nei processi stocastici. Alla luce di tali evidenze, si indaga la possibile esistenza di una relazione di equilibrio di lungo periodo tra le variabili attraverso la metodologia della cointegrazione e modelli VECM.

6.1 Test Augmented Dickey-Fuller (ADF)

Per verificare l'applicabilità del modello VECM, è stata indagata la natura stocastica delle serie tramite il test Augmented Dickey-Fuller (ADF).

```
summary(ur.df(prezzi_consumo_cpi, type="trend", lags=12, selectlags = "BIC"))
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.9092	-0.1733	-0.0117	0.1895	2.0513

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.0700414	0.0793703	0.882	0.377853
z.lag.1	0.0018779	0.0024867	0.755	0.450429
tt	-0.0005161	0.0009837	-0.525	0.600017
z.diff.lag1	0.5793605	0.0391163	14.811	< 2e-16 ***
z.diff.lag2	-0.1842622	0.0446445	-4.127	4.15e-05 ***
z.diff.lag3	0.1381778	0.0393878	3.508	0.000482 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4425 on 649 degrees of freedom

Multiple R-squared: 0.3091, Adjusted R-squared: 0.3038

F-statistic: 58.08 on 5 and 649 DF, p-value: < 2.2e-16

Value of test-statistic is: 0.7552 20.9902 3.127

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-3.96	-3.41	-3.12

```
phi2  6.09  4.68  4.03
phi3  8.27  6.25  5.34
```

```
summary(ur.df(diff(prezzi_consumo_cpi), type="trend"))
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-3.01832 -0.16977 -0.01217  0.18839  2.07289
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.397e-01  3.593e-02   3.889 0.000111 ***
z.lag.1      -5.328e-01  3.814e-02 -13.972 < 2e-16 ***
tt           2.674e-04  9.145e-05   2.924 0.003569 **
z.diff.lag   1.008e-01  3.875e-02   2.602 0.009488 **
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 0.4433 on 661 degrees of freedom

Multiple R-squared: 0.2491, Adjusted R-squared: 0.2457

F-statistic: 73.11 on 3 and 661 DF, p-value: < 2.2e-16

Value of test-statistic is: -13.9724 65.0814 97.6174

Critical values for test statistics:

```
      1pct  5pct 10pct
tau3 -3.96 -3.41 -3.12
phi2  6.09  4.68  4.03
phi3  8.27  6.25  5.34
```

```
summary(ur.df(prezzo_petrolio, type="trend", lags=12, selectlags = "BIC"))
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-21.2561	-1.3877	-0.0238	1.1968	14.7151

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.115938	0.303058	0.383	0.70217
z.lag.1	-0.031753	0.007995	-3.971	7.94e-05 ***
tt	0.003580	0.001216	2.944	0.00335 **
z.diff.lag	0.352096	0.036721	9.588	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.769 on 651 degrees of freedom

Multiple R-squared: 0.1339, Adjusted R-squared: 0.1299

F-statistic: 33.53 on 3 and 651 DF, p-value: < 2.2e-16

Value of test-statistic is: -3.9714 5.3223 7.8996

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-3.96	-3.41	-3.12
phi2	6.09	4.68	4.03
phi3	8.27	6.25	5.34

```
summary(ur.df(prezzo_petrolio, type="drift", lags=12, selectlags = "BIC"))
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression drift

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-22.0829	-1.3714	-0.4054	1.2621	15.9652

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.608561	0.254159	2.394	0.01693 *

```
z.lag.1      -0.013678   0.005152  -2.655   0.00813 **
z.diff.lag   0.342607   0.036794   9.312   < 2e-16 ***
---
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.791 on 652 degrees of freedom
Multiple R-squared: 0.1223, Adjusted R-squared: 0.1196
F-statistic: 45.43 on 2 and 652 DF, p-value: < 2.2e-16

Value of test-statistic is: -2.6549 3.6072

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.43	-2.86	-2.57
phi1	6.43	4.59	3.78

```
summary(ur.df(diff(prezzo_petrolio), type="drift"))
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression drift

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-23.3352	-1.1544	-0.0611	1.3619	15.8015

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.06115	0.14671	0.417	0.677
z.lag.1	-0.67954	0.04480	-15.167	<2e-16 ***
z.diff.lag	0.02358	0.03888	0.606	0.545

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.782 on 662 degrees of freedom
Multiple R-squared: 0.332, Adjusted R-squared: 0.33
F-statistic: 164.5 on 2 and 662 DF, p-value: < 2.2e-16

Value of test-statistic is: -15.1673 115.0237

Critical values for test statistics:

	1pct	5pct	10pct
--	------	------	-------

```
tau2 -3.43 -2.86 -2.57
phi1  6.43  4.59  3.78
```

```
summary(ur.df(prezzi_produzione_ppi, type="trend", lags=12, selectlags = "BIC"))
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-11.2453	-0.4509	0.0246	0.5233	5.9922

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	0.563575	0.207370	2.718	0.00675	**
z.lag.1	-0.011598	0.004431	-2.617	0.00906	**
tt	0.003585	0.001352	2.650	0.00823	**
z.diff.lag1	0.405192	0.038871	10.424	< 2e-16	***
z.diff.lag2	0.108352	0.039130	2.769	0.00578	**

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.509 on 650 degrees of freedom

Multiple R-squared: 0.2152, Adjusted R-squared: 0.2104

F-statistic: 44.56 on 4 and 650 DF, p-value: < 2.2e-16

Value of test-statistic is: -2.6175 5.022 3.5263

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-3.96	-3.41	-3.12
phi2	6.09	4.68	4.03
phi3	8.27	6.25	5.34

```
summary(ur.df(diff(prezzi_produzione_ppi), type="trend"))
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-11.7785	-0.4272	0.0287	0.4961	6.2975

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.1190705	0.1174607	1.014	0.3111
z.lag.1	-0.5005898	0.0407641	-12.280	<2e-16 ***
tt	0.0001517	0.0003042	0.499	0.6181
z.diff.lag	-0.0968700	0.0387555	-2.500	0.0127 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.504 on 661 degrees of freedom

Multiple R-squared: 0.2838, Adjusted R-squared: 0.2806

F-statistic: 87.32 on 3 and 661 DF, p-value: < 2.2e-16

Value of test-statistic is: -12.2802 50.2677 75.4015

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-3.96	-3.41	-3.12
phi2	6.09	4.68	4.03
phi3	8.27	6.25	5.34

I test condotti sui livelli delle tre variabili (CPI, Petrolio, PPI) hanno mostrato statistiche (tau) superiori ai valori critici al 5%, portando al non rifiuto dell'ipotesi nulla di radice unitaria. Al contrario, le medesime prove condotte sulle differenze prime hanno prodotto statistiche significativamente inferiori ai valori critici (p-value < 0.01), confermando che tutte le serie sono integrate di ordine 1, $I(1)$. Essendo le variabili caratterizzate dallo stesso ordine di integrazione, si procede alla verifica della cointegrazione tramite il test di Johansen per identificare possibili relazioni di equilibrio di lungo periodo.

6.2 Test di Johansen

```
train <- window(data_mens, end = c(2015, 12))
test <- window(data_mens, start = c(2016, 1))

vecm <- ca.jo(train, K = 3, type = "trace", ecdet="const")
summary(vecm)
```

```
#####
# Johansen-Procedure #
#####
```

Test type: trace statistic , without linear trend and constant in cointegration

Eigenvalues (lambda):

```
[1] 2.615628e-01 4.291296e-02 1.165919e-02 2.437233e-16
```

Values of teststatistic and critical values of test:

	test	10pct	5pct	1pct
$r \leq 2$		6.44	7.52	9.24 12.97
$r \leq 1$		30.52	17.85	19.96 24.60
$r = 0$		196.99	32.00	34.91 41.07

Eigenvectors, normalised to first column:

(These are the cointegration relations)

	prezzi_consumo_cpi.l3	prezzo_petrolio.l3
prezzi_consumo_cpi.l3	1.0000000	1.000000
prezzo_petrolio.l3	0.6110481	1.834074
prezzi_produzione_ppi.l3	-1.6469000	-2.259087
constant	-11.6859462	71.713149

	prezzi_produzione_ppi.l3	constant
prezzi_consumo_cpi.l3	1.0000000	1.0000000
prezzo_petrolio.l3	0.2702796	0.3238262
prezzi_produzione_ppi.l3	-1.5655270	-1.1353833
constant	40.8435471	-12.6764852

Weights W:

(This is the loading matrix)

	prezzi_consumo_cpi.l3	prezzo_petrolio.l3
prezzi_consumo_cpi.d	-0.006671793	0.000334603
prezzo_petrolio.d	-0.016725631	-0.019019972
prezzi_produzione_ppi.d	-0.007863700	0.003773728

	prezzi_produzione_ppi.l3	constant
prezzi_consumo_cpi.d	0.001169542	-1.263259e-17
prezzo_petrolio.d	0.023453230	1.636155e-16
prezzi_produzione_ppi.d	0.009375474	-2.813711e-16

Basandoci sulla statistica della traccia (trace statistic), confrontiamo i valori calcolati con le soglie critiche:

- Rango $r = 0$: Il valore del test (196.99) supera ampiamente il valore critico all'1% (41.07), rifiutando l'ipotesi di assenza di cointegrazione.
- Rango $r \leq 1$: Il valore (30.52) è ancora superiore al valore critico all'1% (24.60).
- Rango $r \leq 2$: Il valore (6.44) è inferiore al valore critico al 10% (7.52).

Quindi si sceglie $r = 2$ come ordine di cointegrazione.

6.3 Stima del modello VECM

L'analisi prosegue con la stima del modello VECM, che permette di separare le dinamiche di breve periodo dalle relazioni di equilibrio di lungo periodo.

```
VECM <- cajorls(vecm, r=2)

beta <- VECM$beta
beta
```

	ect1	ect2
prezzi_consumo_cpi.l3	1.000000e+00	0.000000
prezzo_petrolio.l3	1.110223e-16	1.000000
prezzi_produzione_ppi.l3	-1.341039e+00	-0.500551
constant	-5.335379e+01	68.190775

Il vettore β estratto rappresenta il legame strutturale stabile tra le variabili nel lungo termine. Questi coefficienti indicano che, nel lungo periodo, esiste una relazione positiva e predominante tra i prezzi alla produzione e quelli al consumo (coefficiente 1.65). I prezzi al consumo sembrano quindi essere fortemente ancorati ai costi di produzione industriali.

```
coeff_vecm <- VECM$rlm$coefficients
coeff_vecm
```

	prezzi_consumo_cpi.d	prezzo_petrolio.d
ect1	-0.00633719	-0.03574560
ect2	-0.00346310	-0.04510420
prezzi_consumo_cpi.dl1	0.23613833	-1.34993464
prezzo_petrolio.dl1	0.06136855	0.45491785
prezzi_produzione_ppi.dl1	-0.01276584	-0.08902686
prezzi_consumo_cpi.dl2	-0.19790373	-1.17084462
prezzo_petrolio.dl2	-0.00622364	0.05483462
prezzi_produzione_ppi.dl2	0.06517686	0.59429057

	prezzi_produzione_ppi.d
ect1	-0.004089972
ect2	0.002116198
prezzi_consumo_cpi.dl1	-0.111770220
prezzo_petrolio.dl1	0.178086794
prezzi_produzione_ppi.dl1	0.029761607
prezzi_consumo_cpi.dl2	-0.538049623
prezzo_petrolio.dl2	0.045858784
prezzi_produzione_ppi.dl2	0.236146321

La stima del modello VECM basata su un rango di cointegrazione pari a due permette di approfondire la complessità delle relazioni di equilibrio che governano il sistema. Attraverso la scomposizione della matrice β , il modello identifica due distinti vettori di cointegrazione, ciascuno dei quali rappresenta un legame strutturale indipendente tra le variabili. Il primo vettore, normalizzato rispetto ai prezzi al consumo, evidenzia una relazione predominante tra il CPI e i prezzi alla produzione. Il secondo vettore isola invece il legame tra la quotazione del petrolio e il PPI, catturando la trasmissione nel lungo periodo dei prezzi del petrolio nei prezzi alla produzione. L'analisi dei coefficienti di

aggiustamento, o pesi α , rivela dinamiche differenziate nella velocità di riallineamento verso questi equilibri. Il prezzo del petrolio emerge come la variabile più reattiva del sistema, mostrando una capacità di correzione degli squilibri significativamente più rapida rispetto alle altre serie. Al contrario, i prezzi al consumo manifestano una lentezza nel riassetarsi, con coefficienti di entità ridotta.

6.4 Rappresentazione VAR del VECM

Per finalizzare l'analisi, il modello VECM è stato convertito in una forma VAR livellata tramite la funzione `vec2var`. Questa operazione permette di esprimere le relazioni di equilibrio stimate precedentemente in un formato utile per la generazione di previsioni dirette sui livelli delle serie storiche, mantenendo al contempo l'informazione strutturale del rango di cointegrazione $r = 2$.

```
modVAR <- vec2var(vecm, r = 2)
modVAR
```

Coefficient matrix of lagged endogenous variables:

A1:

	prezzi_consumo_cpi.l1	prezzo_petrolio.l1
prezzi_consumo_cpi	1.2361383	0.06136855
prezzo_petrolio	-1.3499346	1.45491785
prezzi_produzione_ppi	-0.1117702	0.17808679

	prezzi_produzione_ppi.l1
prezzi_consumo_cpi	-0.01276584
prezzo_petrolio	-0.08902686
prezzi_produzione_ppi	1.02976161

A2:

	prezzi_consumo_cpi.l2	prezzo_petrolio.l2
prezzi_consumo_cpi	-0.4340421	-0.06759219
prezzo_petrolio	0.1790900	-0.40008322
prezzi_produzione_ppi	-0.4262794	-0.13222801

	prezzi_produzione_ppi.l2
prezzi_consumo_cpi	0.07794271
prezzo_petrolio	0.68331743
prezzi_produzione_ppi	0.20638471

A3:


	prezzi_consumo_cpi.l3	prezzo_petrolio.l3
prezzi_consumo_cpi	0.1915665	0.002760541
prezzo_petrolio	1.1350990	-0.099938825
prezzi_produzione_ppi	0.5339597	-0.043742586

	prezzi_produzione_ppi.l3
prezzi_consumo_cpi	-0.05494499
prezzo_petrolio	-0.52377736
prezzi_produzione_ppi	-0.23172077

Coefficient matrix of deterministic regressor(s).

	constant
prezzi_consumo_cpi	0.1019616
prezzo_petrolio	-1.1685272
prezzi_produzione_ppi	0.3625207

```
prev <- predict(modVAR, n.ahead = NROW(test))
consumi_prev <- prev$fcst$prezzi_consumo_cpi[,1]
plot(as.numeric(test[, "prezzi_consumo_cpi"]), type = "l")
lines(consumi_prev, col = 2)
```



Il confronto grafico tra i dati osservati del set di test e le previsioni generate dal modello fornisce indicazioni cruciali sulla capacità del sistema di operare in contesti reali. L'andamento della linea rossa mostra che il modello riesce a seguire in modo sufficiente la traiettoria dei dati fino a tutto il 2019, catturando correttamente la tendenza di fondo dei prezzi al consumo. Tuttavia, emerge una sistematica sottostima dei valori osservati lungo gran parte dell'orizzonte previsivo. Il modello, pur essendo strutturalmente solido, tende a produrre stime più conservative rispetto ai livelli effettivamente raggiunti dal CPI. A partire dal 2020, si osserva una netta divergenza tra le due serie. Questo

scostamento è causato dallo shock globale senza precedenti dovuto alla pandemia di COVID-19. Essendo un evento anomalo ed esogeno, che non trova riscontro nelle dinamiche storiche utilizzate per l'addestramento, il modello non ha gli strumenti statistici per prevederlo né per adattarsi istantaneamente a tale rottura strutturale.

7 Conclusione

L'analisi ha dimostrato che il prezzo del petrolio agisce come principale motore esogeno del sistema, esercitando una pressione significativa e persistente sui prezzi al consumo e alla produzione. Sebbene i test di causalità e le funzioni di risposta agli impulsi abbiano confermato la validità del modello VAR nella cattura delle dinamiche di breve periodo, l'individuazione di una relazione di cointegrazione ha permesso di definire un equilibrio di lungo periodo in cui il CPI risulta fortemente ancorato ai costi industriali. Tuttavia, la fase di previsione ha evidenziato i limiti intrinseci della modellistica lineare: mentre il sistema si è dimostrato affidabile e statisticamente superiore ai modelli ARIMA fino al 2019, l'insorgere della crisi pandemica nel 2020 ha generato una rottura strutturale imprevedibile. Questo scostamento finale sottolinea come, nonostante il rigore tecnico del modello, la previsione macroeconomica rimanga vulnerabile a eventi eccezionali.